

Ejercicio A — Precio de Vivienda

Machine Learning – CS3061

Monzón Gallegos, Alessandro Facundo
Ramírez Chuquimarca, Mateo Elías
Vargas Zeballos, Arantza
Universidad de Ingeniería y Tecnología (UTEC)
Lima, Perú

Abstract—En este informe se desarrolla la implementación de modelos de regresión lineal múltiple y regresión logística utilizando Gradient Descent y la Ecuación Normal sobre un dataset de propiedades inmobiliarias.

I. INTRODUCCIÓN

La predicción de precios de viviendas constituye uno de los problemas más comunes dentro del aprendizaje automático supervisado, debido a la relación existente entre las características de una propiedad y su valor de mercado. En este trabajo se analizan técnicas de regresión lineal múltiple y regresión logística aplicadas a un dataset de propiedades inmobiliarias.

En la primera parte, se implementa un modelo de regresión lineal para estimar el precio de venta de una vivienda a partir de variables como el área, número de habitaciones, antigüedad y distancia al centro de la ciudad. Se estudia tanto la solución analítica mediante la ecuación normal como la optimización iterativa utilizando Gradient Descent.

Posteriormente, en la segunda parte, se aborda un problema de clasificación binaria utilizando regresión logística, donde las propiedades son clasificadas como *PREMIUM* o *ESTÁNDAR* dependiendo de si el precio supera los \$200,000. Finalmente, se comparan distintos modelos univariados y multivariados para evaluar el impacto de cada característica en la predicción.

II. PARTE 1: REGRESIÓN LINEAL MÚLTIPLE

A. Etapa 1.1 – Gradient Descent a Mano

Se utilizaron únicamente los tres primeros registros y la característica Área.

TABLE I
DATASET REDUCIDO

Área (x)	Precio (y)
0.95	1.71
1.23	2.16
1.18	1.96

1) *Datos Escalados*: Parámetros iniciales:

$$w_0 = 0, \quad w_1 = 1.0$$

$$\alpha = 0.1$$

2) *Iteración 1*: Para la primera iteración se utilizaron los parámetros iniciales:

Tomamos solo los 3 primeros datos y una sola variable
 x = área escalada

x	y
0.95	1.71
1.23	2.16
1.18	1.96

Iteración 1.0. $w_0 = 0$ y $w_1 = 1$, $\alpha = 0.1$

Calculamos predicciones y sus errores:

$$\hat{y}_1 = 0 + 1(0.95) = 0.95$$

$$\hat{y}_2 = 0 + 1(1.23) = 1.23$$

$$\hat{y}_3 = 0 + 1(1.18) = 1.18$$

$$e_1 = 0.95 - 1.71 = -0.76$$

$$e_2 = 1.23 - 2.16 = -0.93$$

$$e_3 = 1.18 - 1.96 = -0.78$$

Calculamos su MSE:

$$J = \frac{1}{2n} [(-0.76)^2 + (-0.93)^2 + (-0.78)^2]$$

$$J = \frac{1}{6} [0.5776 + 0.8649 + 0.6084] = 0.3418$$

Calculamos sus gradientes:

$$\frac{\partial J}{\partial w_0} = \frac{1}{3} (-0.76 - 0.93 - 0.78) = -0.8233$$

$$\frac{\partial J}{\partial w_1} = \frac{1}{3} [(-0.76)(0.95) + (-0.93)(1.23) + (-0.78)(1.18)]$$

$$= -0.9288$$

Actualizamos sus pesos:

$$w_0^{(1)} = 0 - 0.1(-0.8233) = 0.0823$$

$$w_1^{(1)} = 1 - 0.1(-0.9288) = 1.0929$$

Fig. 1. Desarrollo completo de la Iteración 1

3) *Iteración 2*: Usando los pesos actualizados de la iteración anterior, se ejecutó la segunda iteración del algoritmo.

Iteración 2: $w_0 = 0.0823$, $w_1 = 1.0929$ y $r = 0.1$

Calculamos predicciones y sus errores:

$$\hat{y}_1 = 0.0823 + 1.0929(0.95) = 1.1206$$

$$\hat{y}_2 = 0.0823 + 1.0929(1.23) = 1.4266$$

$$\hat{y}_3 = 0.0823 + 1.0929(1.18) = 1.3729$$

$$e_1 = 1.1206 - 1.11 = -0.5894$$

$$e_2 = 1.4266 - 2.16 = -0.7334$$

$$e_3 = 1.3729 - 1.96 = -0.5871$$

Calculamos su MSE:

$$J = \frac{1}{6} [(-0.5894)^2 + (-0.7334)^2 + (-0.5871)^2]$$

$$J = \frac{1}{6} (0.3474 + 0.5379 + 0.3447) = 0.2050$$

Calculamos sus gradientes:

$$\frac{\partial J}{\partial w_0} = \frac{1}{3} (-0.5894 - 0.7334 - 0.5871) = -0.6166$$

$$\frac{\partial J}{\partial w_1} = \frac{1}{3} [(-0.5894)(0.95) + (-0.7334)(1.23) + (-0.5871)(1.18)] = -0.7191$$

Actualizamos sus pesos:

$$w_0^{(2)} = 0.0823 - 0.1(-0.6166) = 0.1460$$

$$w_1^{(2)} = 1.0929 - 0.1(-0.7191) = 1.1648$$

Fig. 2. Desarrollo completo de la Iteración 2

4) **Iteración 3:** La tercera iteración continuó el proceso de minimización del error mediante Gradient Descent.

Iteración 3: $w_0 = 0.1460$, $w_1 = 1.1648$ y $r = 0.1$

Calculamos sus predicciones y errores:

$$\hat{y}_1 = 0.1460 + 1.1648(0.95) = 1.2526$$

$$\hat{y}_2 = 0.1460 + 1.1648(1.23) = 1.5787$$

$$\hat{y}_3 = 0.1460 + 1.1648(1.18) = 1.5205$$

$$e_1 = 1.2526 - 1.71 = -0.4574$$

$$e_2 = 1.5787 - 2.16 = -0.5813$$

$$e_3 = 1.5205 - 1.96 = -0.4395$$

Calculamos su MSE:

$$J = \frac{1}{6} [(-0.4574)^2 + (-0.5813)^2 + (-0.4395)^2]$$

$$J = \frac{1}{6} (0.2092 + 0.3379 + 0.1932) = 0.1234$$

Calculamos sus gradientes:

$$\frac{\partial J}{\partial w_0} = \frac{1}{3} (-0.4574 - 0.5813 - 0.4395) = -0.4927$$

$$\frac{\partial J}{\partial w_1} = \frac{1}{3} [(-0.4574)(0.95) + (-0.5813)(1.23) + (-0.4395)(1.18)] = -0.5560$$

Actualizamos sus pesos:

$$w_0^{(3)} = 0.1460 - 0.1(-0.4927) = 0.1953$$

$$w_1^{(3)} = 1.1648 - 0.1(-0.5560) = 1.2204$$

Fig. 3. Desarrollo completo de la Iteración 3

5) **Iteración 4:** Finalmente, la cuarta iteración permitió observar la convergencia progresiva del modelo.

Iteración 4: $w_0 = 0.1953$, $w_1 = 1.2204$ y $r = 0.1$

Calculamos sus predicciones y errores:

$$\hat{y}_1 = 0.1953 + 1.2204(0.95) = 1.3547$$

$$\hat{y}_2 = 0.1953 + 1.2204(1.23) = 1.6964$$

$$\hat{y}_3 = 0.1953 + 1.2204(1.18) = 1.6354$$

$$e_1 = 1.3547 - 1.71 = -0.3553$$

$$e_2 = 1.6964 - 2.16 = -0.4636$$

$$e_3 = 1.6354 - 1.96 = -0.3246$$

Calculamos su MSE:

$$J = \frac{1}{6} [(-0.3553)^2 + (-0.4636)^2 + (-0.3246)^2]$$

$$J = \frac{1}{6} (0.1262 + 0.2149 + 0.1054) = 0.0744$$

Calculamos sus gradientes:

$$\frac{\partial J}{\partial w_0} = \frac{1}{3} (-0.3553 - 0.4636 - 0.3246) = -0.3812$$

$$\frac{\partial J}{\partial w_1} = \frac{1}{3} [(-0.3553)(0.95) + (-0.4636)(1.23) + (-0.3246)(1.18)] = -0.4784$$

Actualizamos sus pesos:

$$w_0^{(4)} = 0.1953 - 0.1(-0.3812) = 0.2334$$

$$w_1^{(4)} = 1.2204 - 0.1(-0.4784) = 1.2682$$

Fig. 4. Desarrollo completo de la Iteración 4

Observación:

Se aprecia una reducción progresiva del error cuadrático medio (MSE) a medida que avanzan las iteraciones del algoritmo.

B. Etapa 1.2 – Solución Computacional

1) **Análisis Exploratorio de Datos:** Antes del entrenamiento del modelo, se realizó un análisis exploratorio sobre las variables del dataset con el objetivo de identificar patrones, relaciones y posibles dependencias entre las características y el precio de las viviendas.

La Figura 5 muestra la dispersión entre los features y la variable objetivo, mientras que la Figura 6 presenta la matriz de correlación entre las variables.




Fig. 5. Relación entre los features y el precio de las viviendas




Fig. 6. Matriz de correlación entre variables

El análisis muestra que el Área presenta la relación más fuerte con el Precio, lo cual explica su alta importancia en los modelos de regresión lineal y posteriormente de la regresión logística.

Asimismo, la Distancia al centro urbano presenta una correlación negativa significativa, consistente con la lógica económica del mercado inmobiliario. Por otro lado, variables como el número de habitaciones y la antigüedad muestran relaciones más débiles o con mayor dispersión, sugiriendo que su aporte al modelo es complementario más que determinante.

2) *Construcción de la Matriz de Datos*: Se construyó la matriz de características:

$$X \in \mathbb{R}^{14 \times 5}$$

incluyendo una columna adicional de unos correspondiente al bias del modelo:

$$X = \begin{bmatrix} 1 & x_{11} & x_{12} & x_{13} & x_{14} \\ 1 & x_{21} & x_{22} & x_{23} & x_{24} \\ \vdots & \vdots & \vdots & \vdots & \vdots \\ 1 & x_{n1} & x_{n2} & x_{n3} & x_{n4} \end{bmatrix}$$

y el vector objetivo:

$$y \in \mathbb{R}^{14 \times 1}$$

3) *Rango de las Variables*: Antes de aplicar normalización, se analizaron los rangos de las variables del dataset.

TABLE II
RANGOS DE LAS VARIABLES

Variable	Mínimo	Máximo
Área	63	195
Habitaciones	2	5
Antigüedad	3	29
Distancia	2.0	22.0

Para la variable objetivo:

TABLE III
RANGO DEL PRECIO

Variable	Mínimo	Máximo
Precio	133600	357400

Debido a la diferencia de escalas entre las variables, se aplicó normalización Z-score antes del entrenamiento del modelo.

$$z = \frac{x - \mu}{\sigma}$$

4) *Ecuación Normal*: La solución cerrada utilizada fue:

$$w = (X^T X)^{-1} X^T y$$

Los pesos obtenidos fueron los siguientes:

TABLE IV
PESOS OBTENIDOS MEDIANTE ECUACIÓN NORMAL

Coeficiente	Valor
w_0	227914.2857
w_1	57795.5478
w_2	10267.2916
w_3	-3104.3643
w_4	-2496.4522

5) *Gradient Descent*: Posteriormente, se implementó Gradient Descent utilizando:

$$lr = 0.01$$

$$epochs = 5000$$

El error utilizado fue Mean Squared Error (MSE), definido como:

$$MSE = \frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2$$

Se utilizó MSE debido a que penaliza con mayor intensidad errores grandes, permitiendo una optimización más estable y diferenciable para esta pequeña muestra.

TABLE V
EVOLUCIÓN DEL MSE DURANTE EL ENTRENAMIENTO

Época	MSE
0	55489455714.29
500	65456677.07
1000	54841242.13
1500	54116234.25
2000	54052822.97
2500	54047276.06
3000	54046790.84
3500	54046748.39
4000	54046744.68
4500	54046744.35

Los pesos finales obtenidos mediante Gradient Descent fueron:

TABLE VI
PESOS OBTENIDOS MEDIANTE GRADIENT DESCENT

Coeficiente	Valor
w_0	227914.2857
w_1	57795.5148
w_2	10267.2699
w_3	-3104.2927
w_4	-2496.5193

Se observa que los coeficientes obtenidos mediante Gradient Descent son prácticamente idénticos a los calculados mediante la Ecuación Normal, lo cual valida la correcta convergencia del algoritmo iterativo.

6) *Convergencia del Modelo*: La Figura 7 muestra la evolución del MSE durante el entrenamiento.




Fig. 7. Convergencia del MSE durante el entrenamiento

Asimismo, la Figura 8 muestra el ajuste de la regresión lineal y la comparación entre valores reales y predichos.




Fig. 8. Comparación entre valores reales y predichos

7) *Calidad del Modelo*: El coeficiente de determinación obtenido fue:

$$R^2 = 0.9847520878395251$$

Este resultado indica que el modelo logra explicar aproximadamente el 98.47% de la variabilidad presente en los precios de las viviendas, evidenciando un excelente ajuste sobre el dataset utilizado.

8) *Comparación de Normalización*: Finalmente, se comparó el desempeño del modelo utilizando distintos métodos de normalización.

TABLE VII
COMPARACIÓN ENTRE MÉTODOS DE NORMALIZACIÓN

Método	MSE	RMSE	R^2
Sin normalizar	inf	inf	$-\infty$
Z-score	54046744.33	7351.65	0.9848
Min-Max	58421722.20	7643.41	0.9835

La ausencia de normalización provocó divergencia durante el entrenamiento debido a las grandes diferencias de escala entre las variables del dataset. En particular, características como el área y el precio poseen magnitudes considerablemente mayores que variables como habitaciones o distancia, lo que genera gradientes extremadamente grandes y actualizaciones inestables durante Gradient Descent.

Por otro lado, tanto la normalización Z-score como Min-Max permitieron una convergencia estable al reducir las diferencias de escala entre los features. Sin embargo, Z-score obtuvo un desempeño ligeramente superior respecto a Min-Max, reflejado en un menor MSE y un mayor valor de R^2 .

Esto ocurre porque la normalización Z-score centra los datos alrededor de media cero y desviación estándar uno:

$$z = \frac{x - \mu}{\sigma}$$

lo que produce distribuciones más balanceadas y favorece una optimización más eficiente para Gradient Descent. Además, Z-score es menos sensible a la presencia de valores extremos en comparación con Min-Max, ya que este último comprime todos los datos dentro del intervalo $[0, 1]$, pudiendo verse afectado por outliers.

En consecuencia, Z-score permitió una convergencia más rápida, estable y precisa para el modelo de regresión lineal implementado.

La Figuras siguientes muestran la diferencia en la convergencia del MSE entre datos normalizados y no normalizados.




Fig. 9. Comparación de convergencia con normalización




Fig. 10. Comparación de convergencia sin normalización

Además, la comparación final de R^2 fue:

$$R^2_{sin\ normalizar} = -\infty$$

$$R^2_{Z-score} = 0.9847520878395251$$

$$R^2_{MinMax} = 0.9835177992779494$$

9) *Interpretación Económica:* Los resultados obtenidos presentan una interpretación económicamente coherente con el comportamiento esperado del mercado inmobiliario.

En primer lugar, el área de la vivienda tiene una relación positiva con el precio, indicando que propiedades más grandes tienden a ser más costosas debido a su mayor superficie habitable y valor comercial.

Asimismo, el número de habitaciones influye positivamente en el precio de la propiedad, ya que viviendas con mayor cantidad de habitaciones suelen resultar más atractivas para compradores y familias.

Por otro lado, la antigüedad presenta una relación negativa con el precio. Esto refleja que las propiedades más antiguas tienden a depreciarse con el tiempo debido al desgaste y mayores costos de mantenimiento.

De manera similar, la distancia al centro urbano también afecta negativamente el valor de la propiedad, dado que ubicaciones más alejadas suelen tener menor demanda y menor acceso a servicios y centros laborales.

En conjunto, los resultados muestran relaciones coherentes con tendencias típicas del mercado inmobiliario, destacando el área como el factor de mayor influencia dentro del modelo.

10) *Predicción:* Finalmente, se realizó una predicción utilizando las siguientes características:

$$x = [120, 3, 10, 7]$$

El precio estimado por el modelo fue:

$$\hat{y} = 217107.63 \text{ USD}$$

III. PARTE 2: REGRESIÓN LOGÍSTICA

A. Etapa 2.1 – Variable Objetivo Binaria

Se construyó la variable objetivo binaria definida como:

$$y_{bin} = \begin{cases} 1 & \text{si Precio} > 200,000 \text{ (PREMIUM)} \\ 0 & \text{si Precio} \leq 200,000 \text{ (ESTÁNDAR)} \end{cases}$$

La distribución de clases obtenida fue:

TABLE VIII
DISTRIBUCIÓN DE CLASES

Clase	Cantidad
PREMIUM (1)	8
ESTÁNDAR (0)	6




Fig. 11. Distribución de clases PREMIUM vs ESTÁNDAR

1) *Análisis de balance del dataset*: El dataset puede considerarse **relativamente balanceado**, ya que la proporción entre clases no es perfectamente uniforme, pero tampoco presenta un desbalance severo.

En este caso, la clase mayoritaria (PREMIUM) representa aproximadamente el:

$$\frac{8}{14} \approx 57.1\%$$

mientras que la clase minoritaria (ESTÁNDAR) representa:

$$\frac{6}{14} \approx 42.9\%$$

Dado que ambas clases están dentro de un rango cercano al 50%, no se espera un sesgo fuerte hacia una sola clase, lo cual permite que métricas como accuracy sean razonablemente informativas. Sin embargo, aún es importante complementar el análisis con precision, recall y F1-score para evitar interpretaciones engañosas en caso de errores asimétricos.

B. Análisis Exploratorio

Los scatterplots y la matriz de correlación muestran que el área presenta la relación positiva más clara con el precio, además de una separación visible entre las clases PREMIUM y ESTÁNDAR.




Fig. 12. Dispersión de variables vs Precio (con separación de clases)




Fig. 13. Matriz de correlación entre variables

En contraste, variables como la antigüedad presentan mayor dispersión, aunque mantienen una tendencia negativa consistente con la intuición económica del problema.

C. Modelos Logísticos Univariados

Se entrenaron modelos de regresión logística con una sola variable utilizando Binary Cross-Entropy como función de pérdida.

TABLE IX
MODELO UNIVARIADO - ÁREA

Parámetro	Valor
w_0	0.6249
w_1	2.4087
Accuracy	0.8571

1) *Modelo usando Área*: El área resulta ser el mejor predictor individual, ya que presenta la mayor accuracy entre los modelos univariados.

TABLE X
MODELO UNIVARIADO - HABITACIONES

Parámetro	Valor
w_0	0.2857
w_2	-0.0367
Accuracy	0.5714

2) *Modelo usando Habitaciones:*

TABLE XI
MODELO UNIVARIADO - ANTIGÜEDAD

Parámetro	Valor
w_0	0.3013
w_3	0.4509
Accuracy	0.5000

3) *Modelo usando Antigüedad:*

TABLE XII
MODELO UNIVARIADO - DISTANCIA

Parámetro	Valor
w_0	0.2932
w_4	0.3209
Accuracy	0.6429

4) *Modelo usando Distancia:*

5) *Interpretación de modelos univariados:* Los resultados de los modelos logísticos univariados permiten analizar la capacidad predictiva individual de cada variable en la clasificación de propiedades como PREMIUM o ESTÁNDAR.

Comparando los resultados, se observa una jerarquía clara en términos de poder predictivo:

- **Área (0.8571)** es el mejor predictor individual, lo cual es consistente con la relación observada en el análisis exploratorio, donde esta variable presenta la correlación más fuerte con el precio.
- **Distancia (0.6429)** muestra una capacidad predictiva intermedia, lo que sugiere que la ubicación influye en la clasificación, pero no es suficiente por sí sola para separar completamente las clases.
- **Habitaciones (0.5714)** presenta un desempeño cercano al aleatorio, lo cual indica que esta variable tiene un aporte limitado en ausencia de otras características.
- **Antigüedad (0.5000)** no muestra capacidad discriminativa, comportándose prácticamente como un clasificador aleatorio.

Estos resultados confirman que el problema no es univariado, sino multivariado, ya que ninguna variable por sí sola logra capturar completamente la estructura del fenómeno.

Adicionalmente, se observa una coherencia consistente entre el análisis exploratorio y el desempeño de los modelos univariados. En particular, la variable Área no solo presenta la mayor correlación con el precio en la matriz de correlación, sino que también obtiene el mejor desempeño predictivo en el modelo univariado.

Este comportamiento valida la relación entre el análisis estadístico previo y la capacidad predictiva del modelo, lo cual sugiere que las variables con mayor correlación lineal tienden a aportar mayor información discriminativa en tareas de clasificación logística.

D. *Modelo Logístico Completo*

El modelo completo utiliza las cuatro variables:

$$\hat{p} = \sigma(w_0 + w_1x_1 + w_2x_2 + w_3x_3 + w_4x_4)$$

TABLE XIII
MODELO LOGÍSTICO COMPLETO

Coficiente	Valor
w_0	0.7637
w_1	2.8147
w_2	0.0141
w_3	-0.3690
w_4	0.6973

El modelo logístico completo obtiene un desempeño significativamente superior al de los modelos univariados, alcanzando un:

$$Accuracy = 0.9286$$

Este incremento confirma que las variables no actúan de forma independiente, sino que existe una interacción implícita entre ellas que solo puede ser capturada mediante un modelo multivariado.




Fig. 14. Curva de probabilidad del modelo logístico completo

E. *Matriz de Confusión*

La matriz de confusión del modelo completo permite analizar el tipo de errores cometidos por el clasificador.




Fig. 15. Matriz de confusión del modelo logístico completo

A partir de la matriz:

$$\begin{bmatrix} 5 & 1 \\ 0 & 8 \end{bmatrix}$$

se observa que:

- El modelo clasifica correctamente la mayoría de los casos.
- No presenta falsos negativos (FN = 0), lo cual es particularmente importante porque evita omitir propiedades PREMIUM.
- El único error corresponde a un falso positivo, lo cual es menos crítico en este contexto.

En problemas de clasificación inmobiliaria, este comportamiento es preferible, ya que es más aceptable sobreestimar una propiedad que subestimarla.

F. Predicción de una nueva propiedad

Para una nueva observación:

$$x = [175, 4, 8, 6]$$

el modelo estima:

$$P(\text{PREMIUM}) = 0.9793$$

El resultado indica una alta probabilidad de pertenecer a la clase PREMIUM, lo cual es consistente con las características de la propiedad (alto área y moderada distancia al centro).

G. Comparación de normalización




Fig. 16. Convergencia del error (Binary Cross Entropy) bajo diferentes esquemas de normalización

Se evaluaron tres configuraciones del modelo:

TABLE XIV
COMPARACIÓN DE MODELOS

Modelo	Accuracy	Precision	Recall
Sin normalizar	0.7857	1.00	0.625
Z-score	0.9286	0.8889	1.00
Min-Max	0.9286	0.8889	1.00

1) *Interpretación de métricas:* Cada métrica aporta una visión distinta del desempeño del modelo:

- **Accuracy:** mide el rendimiento global, pero puede ocultar errores importantes en clases minoritarias.
- **Precision:** mide la confiabilidad de las predicciones positivas (PREMIUM).
- **Recall:** mide la capacidad del modelo para detectar correctamente los casos PREMIUM.
- **F1-score:** balance entre precisión y recall.

En este caso, el modelo sin normalización presenta un recall significativamente menor (0.625), lo que implica que no logra identificar todas las propiedades PREMIUM (falsos negativos). Este tipo de error es crítico en aplicaciones inmobiliarias, donde omitir una propiedad de alto valor puede ser más costoso que clasificar incorrectamente una de menor valor.

Por el contrario, los modelos con normalización presentan recall perfecto (1.0), lo cual los hace más adecuados para este problema.




Fig. 17. Métricas del modelo con normalización Z-score




Fig. 18. Métricas del modelo con normalización Min-Max




Fig. 19. Métricas del modelo sin normalización

Dado que la regresión logística no optimiza directamente el coeficiente de determinación R^2 , se utilizó el pseudo- R^2 de McFadden como métrica complementaria de bondad de ajuste.

TABLE XV
COMPARACIÓN DE PSEUDO- R^2 ENTRE MODELOS

Modelo	Pseudo- R^2
Sin normalizar	0.8550
Z-score	0.9790
Min-Max	0.9547

Los resultados muestran que el modelo entrenado con normalización Z-score obtiene el mayor pseudo- R^2 , indicando un mejor ajuste general respecto a los demás enfoques evaluados.

Aunque el modelo sin normalización alcanza un valor relativamente alto, presenta menor estabilidad numérica y peores métricas de clasificación, especialmente en recall. Esto evidencia que un buen ajuste parcial no garantiza necesariamente un mejor comportamiento predictivo.

Por otro lado, Min-Max también mejora considerablemente el desempeño respecto al modelo sin normalizar, aunque ligeramente por debajo de Z-score. Esto sugiere que centrar las variables alrededor de media cero y desviación estándar unitaria favorece una convergencia más estable del algoritmo de optimización.

En conclusión, la normalización mejora significativamente tanto la estabilidad numérica como la capacidad predictiva del modelo logístico, siendo Z-score el método más consistente para este problema.

IV. CONCLUSIONES

A lo largo de este trabajo se aplicaron modelos de regresión lineal y regresión logística para analizar y predecir el comportamiento del mercado inmobiliario utilizando variables relacionadas con características físicas y de ubicación de las viviendas.

En la primera parte, correspondiente a regresión lineal múltiple, se comprobó que variables como el área y el número de habitaciones presentan una relación positiva con el precio de las propiedades, mientras que la antigüedad y la distancia al centro urbano afectan negativamente el valor de mercado. Los resultados obtenidos mediante Ecuación Normal y Gradient Descent fueron prácticamente equivalentes, lo cual valida la correcta implementación del algoritmo iterativo.

Asimismo, se evidenció la importancia de la normalización de datos en algoritmos basados en optimización. El entrenamiento sin normalización presentó divergencia numérica debido a las diferencias de escala entre variables, mientras que los métodos Z-score y Min-Max permitieron una convergencia estable. Entre ellos, Z-score obtuvo el mejor desempeño general, alcanzando menor error y mayor coeficiente R^2 .

El análisis de la evolución del MSE permitió observar el proceso de convergencia del modelo durante el entrenamiento. Además, el alto valor de R^2 obtenido demuestra que el modelo lineal logra explicar adecuadamente la variabilidad del precio de las viviendas en este dataset.

En la segunda parte, correspondiente a regresión logística, se transformó el problema en una tarea de clasificación binaria para determinar si una propiedad pertenece a la categoría PREMIUM o ESTÁNDAR. Los modelos univariados mostraron

que el área es la variable individual con mayor capacidad predictiva, mientras que variables como antigüedad y habitaciones presentan menor capacidad discriminativa cuando se utilizan de forma aislada.

El modelo logístico completo obtuvo un desempeño significativamente superior al integrar simultáneamente todas las variables, alcanzando altos valores de accuracy, recall y F1-score. En particular, el recall perfecto obtenido con los modelos normalizados indica que el sistema fue capaz de identificar correctamente todas las propiedades PREMIUM del dataset.

La matriz de confusión permitió analizar el comportamiento real del clasificador y evidenció que los errores cometidos fueron mínimos. Además, las métricas evaluadas demostraron que accuracy por sí sola no es suficiente para evaluar un modelo de clasificación, especialmente cuando existen posibles desbalances entre clases. Por ello, métricas como precision, recall y F1-score resultan fundamentales para comprender el impacto real de los errores del modelo.

Finalmente, este trabajo permitió comprender de manera práctica el funcionamiento de algoritmos fundamentales de Machine Learning, así como la importancia del preprocesamiento, la interpretación de métricas y el análisis exploratorio de datos para construir modelos predictivos robustos y coherentes con el contexto del problema.

REFERENCES

- [1] Google Colab, *Ejercicio A — Precio de Vivienda - Etapa 1.2*, Disponible en: https://colab.research.google.com/drive/1gLcu7IGxCuxkBHZ_vHcMI9npTGuqSmec?usp=sharing
- [2] Google Colab, *Ejercicio A — Precio de Vivienda - Etapa 2*, Disponible en: https://colab.research.google.com/drive/15nScPcvi11hB7_Z3OpP8d3ggRTDWJiXO?usp=sharing